statistics (/archive/?tag=statistics) KS test (/archive/?tag=KS+test)

Kolmogorov-Smirnov test

公開日: 2023-07-02
更新日: 2023-08-13

Table of Contents

- KS testのスコープ
- KS Testの考え方
  - なぜsupremumが未知の分布に依存しないのか？
  - Kolmogorov-Smirnov test statistics
- Pythonで実装
- References

KS testのスコープ

$$X_1, X_2, \cdots, X_n \sim_{i.i.d} \mathbb{P} \tag{1}$$

とデータが与えられたとき, 以下のような形で帰無仮説を設定する場合を考えます

$$H_0 : \mathbb{P} = \mathbb{P}_0$$
$$H_1 : \mathbb{P} \neq \mathbb{P}_0$$

$\mathbb{P}$が離散分布ならば「**chi-squared goodness-of-fit test**」で検定することができますが, $\mathbb{P}$が連続分布の場合, 検定手法の一つとして「**Kolmogorov-Smirnov test**」を用いることができます.

KS Testの考え方

(1)同様に, $X_1, X_2, \cdots, X_n \sim_{i.i.d} \mathbb{P}$ を考えます. このとき, empirical c.d.fは以下のように定義されます:

$$F_n(x) = \mathbb{P}_n(X \leq x) = \frac{1}{n} \sum_{i \in N} I(X_i \leq x) \tag{2}$$

- x以下で観測されるsample pointsの割合を表している

上記(2)について, 大数の法則により, 任意の $x \in \mathbb{R}$について以下の式が成立します:

$$F_n(x) \to \mathbb{E}[I(X_i \leq x)] = \mathbb{P}(X|i \leq x) = F(x) \tag{3}$$

任意の $x \in \mathbb{R}$について成立するので, (3)より

$$\sup_{x \in \mathbb{R}} |F_n(x) - F(x)| \to 0 \tag{4}$$

KS testはこのsupremumが未知の分布 $\mathbb{P}$に依存しないことに着目した統計量という特徴があります.

なぜsupremumが未知の分布に依存しないのか？

<u>Theorem</u>

$F(x)$が連続ならば,

$$\sup_{x \in \mathbb{R}} |F_n(x) - F(x)|$$

はFの形状に依存しない

Proof

Fの逆関数を以下のように定義します:

$$F^{-1}(y) = \min\{x : F(x) \geq y\}$$

このとき以下の式が成立します:

$$\mathbb{P}\left(\sup_{x\in\mathbb{R}} |F_n(x) - F(x)| \leq t\right) = \mathbb{P}\left(\sup_{y\in[0,1]} |F_n(F^{-1}(y)) - F(F^{-1}(y))| \leq t\right)$$

empirical c.d.fの定義より

$$\begin{aligned} F_n(F^{-1}(y)) &= \frac{1}{n}\sum_{i\in N} I(X_i \leq F^{-1}(y)) \\ &= \frac{1}{n}\sum_{i\in N} I(F(X_i) \leq y) \end{aligned}$$

したがって,

$$\mathbb{P}\left(\sup_{y\in[0,1]} |F_n(F^{-1}(y)) - y| \leq t\right) = \mathbb{P}\left(\sup_{y\in[0,1]} \left|\frac{1}{n}\sum_{i\in N} I(F(X_i) \leq y) - y\right| \leq t\right)$$

また,

$$\begin{aligned} \mathbb{P}(F(X_1) \leq t) &= \mathbb{P}(X_1 \leq F^{-1}(t)) \\ &= F(F^{-1}(t)) \\ &= t \end{aligned}$$

上記より, c.d.f $F(X_i)$は確率分布がどんな形状であろうとも連続確率変数ならば $[0,1]$区間の一様分布になることがわかります. したがって, $U_i = F(X - i)$とすると $U_i \sim Unif(0,1)$なので

$$\mathbb{P}\left(\sup_{y\in[0,1]} |F_n(F^{-1}(y)) - y| \leq t\right) = \mathbb{P}\left(\sup_{y\in[0,1]} \left|\frac{1}{n}\sum_{i\in N} I(U_i \leq y) - y\right| \leq t\right)$$

よって題意は示された.

(証明終了)

Kolmogorov-Smirnov test statistics

Kolmogorov-Smirnov distribution

$$\mathbb{P}\left(\sqrt{n}\sup_{x\in\mathbb{R}}\left|F_n(x) - F(x)\right| \leq t\right) \to H(t) = 1 - 2\sum_{j=1}^{\infty}(-1)^{j-1}\exp(-2j^2t)$$

この $H(t)$ はKolmogorov-Smirnov distributionのc.d.f

KS testの統計量は以下のように表される

$$D_n = \sqrt{n}\sup_{x\in\mathbb{R}} |F_n(x) - F_0(x)|$$

- 帰無仮説が正しい場合, nが十分大きいとD_nはKolmogorov-Smirnov distributionに漸近的に収束する.
- 帰無仮説が成立しない場合, FはLLNより真のc.d.f関数に収束する

帰無仮説が成立しない場合, nが十分大きいと,

$$\begin{aligned} &\sup_{x\in\mathbb{R}} |F_n(x) - F_0(x)| > \delta \\ &D_n = \sqrt{n}\sup_{x\in\mathbb{R}} |F_n(x) - F_0(x)| > \sqrt{n}\delta \end{aligned}$$

つまり, H_0が成立性ない場合, nが十分大きいと $D_n > \sqrt{n}\delta \to \infty$となる. この性質を利用して, KS testでは次のような形で棄却レベルαと統計量の関係を定義している

$$\begin{aligned} \alpha &= Pr(\text{reject } H_0 | H_0) \\ &= \mathbb{P}(D_n \geq c | H_0) \\ &\approx 1 - H(c) \end{aligned}$$

Pythonで実装

Pythonでは `scipy` パッケージを用いれば `kstest` コマンドがありますが，`method='asymp'` の場合は以下と同様の挙動となります(defaultは `exact`):

```
import numpy as np
from scipy import stats
import statsmodels.api as sm
from scipy.stats import kstwobign
np.random.seed(42)

## scipy.stats.kstest
x = stats.norm.rvs(size=100)
res = stats.kstest(x, stats.norm.cdf, method='asymp')
print(res)
>> KstestResult(statistic=0.10357070563896065, pvalue=0.23367246360310912, stati

## 再現
def calculate_kstest(data, cdf):
    data = np.sort(data)
    sqrt_n = np.sqrt(len(data))
    ecdf = sm.distributions.ECDF(data)

    gaps = np.column_stack([np.abs(np.r_[0, ecdf(data[:-1])] - stats.norm.cdf(da
                            np.abs(ecdf(data) - stats.norm.cdf(data))])
    gaps = np.max(gaps, axis=1, keepdims=False)
    data_idx = np.argmax(gaps)
    max_diff= np.max(gaps)
    D_n = max_diff * sqrt_n
    pval = 1 - kstwobign.cdf(D_n)

    return max_diff, pval, data[data_idx], D_n, ecdf


max_diff, p_val, sup_x_loc, D_n, ecdf = calculate_kstest(x, stats.norm.cdf)
print(calculate_kstest(x, stats.norm.cdf)[:-2])
>> (0.10357070563896065, 0.23367246360310912, 0.37569801834567196)
```

References

- KS test lecture note (https://ocw.mit.edu/courses/18-443-statistics-for-applications-fall-2006/0c5a824a932b841205b7bb4d27229abc_lecture14.pdf)

Share Buttons

Share on:

Feature Tags

統計 (/archive/?tag=%E7%B5%B1%E8%A8%88) Python (/archive/?tag=Python)

math (/archive/?tag=math) Linux (/archive/?tag=Linux)

Ubuntu 20.04 LTS (/archive/?tag=Ubuntu+20.04+LTS) Shell (/archive/?tag=Shell)

English (/archive/?tag=English) git (/archive/?tag=git)

方法論 (/archive/?tag=%E6%96%B9%E6%B3%95%E8%AB%96)

Ubuntu 22.04 LTS (/archive/?tag=Ubuntu+22.04+LTS)

統計検定 (/archive/?tag=%E7%B5%B1%E8%A8%88%E6%A4%9C%E5%AE%9A)

競技プログラミング (/archive/?tag=%E7%AB%B6%E6%8A%80%E3%83%97%E3%83%AD%E3%82%B0%E3%83%A9%E3%83%9F%E3%83%B3%E3%82%B0)

フーリエ解析 (/archive/?tag=%E3%83%95%E3%83%BC%E3%83%AA%E3%82%A8%E8%A7%A3%E6%9E%90)

前処理 (/archive/?tag=%E5%89%8D%E5%87%A6%E7%90%86) SQL (/archive/?tag=SQL)

coding (/archive/?tag=coding)

コミュニケーション (/archive/?tag=%E3%82%B3%E3%83%9F%E3%83%A5%E3%83%8B%E3%82%B1%E3%83%BC%E3%82%B7%E3%83%A7%E3%83%B3)

Network (/archive/?tag=Network) ssh (/archive/?tag=ssh)

将棋 (/archive/?tag=%E5%B0%86%E6%A3%8B)

Data visualization (/archive/?tag=Data+visualization) Docker (/archive/?tag=Docker)

Econometrics (/archive/?tag=Econometrics) VSCode (/archive/?tag=VSCode)

statistical inference (/archive/?tag=statistical+inference)

GitHub Pages (/archive/?tag=GitHub+Pages) apt (/archive/?tag=apt)

development (/archive/?tag=development)

システム管理 (/archive/?tag=%E3%82%B7%E3%82%B9%E3%83%86%E3%83%A0%E7%AE%A1%E7%90%86)

Coffee (/archive/?tag=Coffee) cloud (/archive/?tag=cloud)

数値計算 (/archive/?tag=%E6%95%B0%E5%80%A4%E8%A8%88%E7%AE%97)

素数 (/archive/?tag=%E7%B4%A0%E6%95%B0) Book (/archive/?tag=Book)

Font (/archive/?tag=Font) Metrics (/archive/?tag=Metrics) Poetry (/archive/?tag=Poetry)

Ubuntu 24.04 LTS (/archive/?tag=Ubuntu+24.04+LTS) architecture (/archive/?tag=architecture)

aws (/archive/?tag=aws) shell (/archive/?tag=shell) systemctl (/archive/?tag=systemctl)

テンプレート (/archive/?tag=%E3%83%86%E3%83%B3%E3%83%97%E3%83%AC%E3%83%BC%E3%83%88)

データ構造 (/archive/?tag=%E3%83%87%E3%83%BC%E3%82%BF%E6%A7%8B%E9%80%A0)

ポワソン分布 (/archive/?tag=%E3%83%9D%E3%83%AF%E3%82%BD%E3%83%B3%E5%88%86%E5%B8%83)

会計分析 (/archive/?tag=%E4%BC%9A%E8%A8%88%E5%88%86%E6%9E%90)

文字コード (/archive/?tag=%E6%96%87%E5%AD%97%E3%82%B3%E3%83%BC%E3%83%89)

環境構築 (/archive/?tag=%E7%92%B0%E5%A2%83%E6%A7%8B%E7%AF%89)

論文 (/archive/?tag=%E8%AB%96%E6%96%87) App (/archive/?tag=App)

Bayesian (/archive/?tag=Bayesian) Dynamic Programming (/archive/?tag=Dynamic+Programming)

Keyboard (/archive/?tag=Keyboard) Processing (/archive/?tag=Processing) R (/archive/?tag=R)

Steam (/archive/?tag=Steam) filesystem (/archive/?tag=filesystem)

quarto (/archive/?tag=quarto) regex (/archive/?tag=regex)

Leave a Comment
(注意：GitHub Accountが必要となります)

0 Comments - *powered by utteranc.es*

Write Preview

Sign in to comment

Styling with Markdown is supported

Sign in with GitHub

(https://github.com/RyoNakagami)

Copyright © Ryo's Tech Blog 2025
Powered by Ryo's Tech Blog (https://ryonakagami.github.io) | Star 1