9. 点推定量とその評価

2025 後期 3H606 数理科学入門 (統計系)–#12,#13

Jan 6, 13, 2026

数理環境論 Room 742
Email: ZHOU YI <zhouy@people.kobe-u.ac.jp>

キーワード

- 点推定量の導出方法
  - モーメント法 Method of moments
  - 最尤法 Method of maximum likelihood
  - ベイズ法 Bayesian method
- 推定量の評価法
  - 有限標本における評価指標
    - 平均２乗誤差 Mean squared error（精度）
    - 偏り Bias（正確性）
    - 最良不偏推定量 Best unbiased estimator
  - 無限標本における評価指標（漸近的評価）
    - 一致性 Consistency（漸近的正確性）
    - 有効性 Efficiency（漸近的精度）

点推定 Point estimation

Def 9.1　点推定量 Point estimator

標本の関数 $W(X_1, \ldots, X_n)$ として表されるすべての関数を指す

- あらゆる統計量 (Statistic) [1]は、点推定量である
- 推定値 (Estimate)：具体的に実現された値 $W(x_1, \ldots, x_n)$
- 2 つの課題
  1. 推定量の導出方法
  2. 推定方法の違いによって得られる推定量が異なる場合、どれを採用すべきか

[1] Def 7.4

モーメント法 Method of moments[3]

$X_1, \ldots, X_n \overset{i.i.d.}{\sim} f(x|\theta_1, \ldots, \theta_k)$ とする

標本モーメント	母モーメント
$m_1 = \frac{1}{n}\sum_{i=1}^n X_i$	$\mu_1' = E[X] = \mu_1'(\theta_1, \ldots, \theta_k)$
$m_2 = \frac{1}{n}\sum_{i=1}^n X_i^2$	$\mu_2' = E[X^2] = \mu_2'(\theta_1, \ldots, \theta_k)$
$\vdots$	$\vdots$
$m_k = \frac{1}{n}\sum_{i=1}^n X_i^k$	$\mu_k' = E[X^k] = \mu_3'(\theta_1, \ldots, \theta_k)$

大数の法則より[2]，$m_k \xrightarrow{P} \mu_k'$

$$\begin{cases} m_1 = \mu_1'(\theta_1, \ldots, \theta_k) \\ m_2 = \mu_2'(\theta_1, \ldots, \theta_k) \\ \qquad\vdots \\ m_k = \mu_k'(\theta_1, \ldots, \theta_k) \end{cases} \Rightarrow (\theta_1, \ldots, \theta_k) = (\tilde{\theta}_1, \ldots, \tilde{\theta}_k)$$

$(\tilde{\theta}_1, \ldots, \tilde{\theta}_k)$: モーメント推定量（moment estimator）

[2] 大数の法則と言う場合，通常は大数の弱法則 WLLN（Thm8.3）を指すことが多い
[3] 最も古い歴史を持つ推定手法。1800 年代後半、Karl Pearson によって提唱された。

Ex 9.2　Bernoulli 分布

$X_1, \ldots, X_n \overset{i.i.d.}{\sim} Bernoulli(p)$ とする（$\theta_1 = p$）

$$m_1 = \bar{X} \quad \mu_1' = p \Rightarrow \bar{X} = p \Rightarrow \tilde{p} = \bar{X}$$

Ex 9.3　正規分布

$X_1, \ldots, X_n \overset{i.i.d.}{\sim} N(\mu, \sigma^2)$ とする（$\theta_1 = \mu, \theta_2 = \sigma^2$）

$$\begin{aligned} m_1 &= \bar{X} & \mu_1' &= \mu \\ m_2 &= \tfrac{1}{n}\sum X_i^2 & \mu_2' &= \mu^2 + \sigma^2 \end{aligned}$$

$$\Rightarrow \begin{cases} \bar{X} = \mu \\ \frac{1}{n}\sum X_i^2 = \mu^2 + \sigma^2 \end{cases} \Rightarrow \tilde{\mu} = \bar{X}, \tilde{\sigma}^2 = \frac{1}{n}\sum (X_i - \bar{X})^2$$

Ex 9.4　二項分布（課題）

$X_1, \ldots, X_n \overset{i.i.d.}{\sim} Binomial(n, p)$ とする（$\theta_1 = n, \theta_2 = p$）

最尤法 Method of maximum likelihood

Def 9.5　尤度関数 Likelihood function

$X_1, \ldots, X_n \overset{i.i.d.}{\sim} f(x|\theta_1, \ldots, \theta_k)$ とする．尤度関数は以下のように定義される

$$L(\theta) = L(\theta_1, \ldots, \theta_k \mid x_1, \ldots, x_n) = \prod_{i=1}^{n} f(x_i \mid \theta)$$

対数尤度関数（log-likelihood function）：$\ell(\theta) = \log L(\theta) = \sum_{i=1}^{n} \log f(x_i \mid \theta)$

Def 9.6　最尤推定量 Maximum likelihood estimator, MLE

各固定された標本点 $\mathbf{x} = (x_1, x_2, \ldots, x_n)$ において，尤度関数もしくは対数尤度関数を最大にする θ の解 $\hat{\theta}(\mathbf{x})$

Thm 9.7　MLE の不変性

$\hat{\theta}$ が θ の MLE であるとする．θ の任意の関数 $\tau(\theta)$ に対して、その関数の MLE は $\tau(\hat{\theta})$ となる

MLE の導出：全域的最大値（Global Maximum）を見つけ出す

1. 微分による候補の選定：尤度関数が（θ_i について）微分可能である場合、MLE の候補は、以下の連立方程式を解くことで得られる値 $(\theta_1, \ldots, \theta_k)$ となる
$$\frac{\partial}{\partial \theta_i} L(\theta|\mathbf{x}) = 0, \quad i = 1, \ldots, k$$
2. 必要条件としての微分：上式の解は、あくまで MLE の候補であることに注意が必要である。
   - 必要条件: 1 次微分が 0 であることは、最大値をとるための必要条件であって、十分条件ではない
   - 極値の性質: 1 次微分が 0 となる点は、極大値・最大値だけでなく、局所的/全域的最小値、あるいは変曲点である可能性がある
3. 境界値の確認：1 次微分が 0 となる点は、関数の定義域の内部にある極値のみを特定する
   - 境界での極値: もし最大値が定義域の境界（端点）で発生する場合、その点での 1 次微分は 0 になるとは限らない
   - 必須の作業: 境界値については別途確認を行い、全域的な最大値を見つけ出す必要がある

Supp 9.8　極大・小値 / 最大・小値の定義

- 極値 (Local Extrema) 関数のある限定された範囲（近傍）において、値が最も大きい、または小さい状態を指す
  - 極大・小値 (Local Maximum・Minimum)：周辺のどの点よりも高い・低い値をとる点
  - 極大値: $f'(x) = 0$ かつ $f''(x) < 0$ のとき
  - 極小値: $f'(x) = 0$ かつ $f''(x) > 0$ のとき
  - 判定不能/変曲点: $f''(x) = 0$
- 最適値 (Global Extrema) 関数の定義域全体を通して、値が最も大きい、または小さい状態を指す
  - 最大・小値 (Global Maximum・Minimum)：定義域全体で最も高い・低い値
  - 内部の極値と境界値（定義域 $a \leq x \leq b$ における $f(a)$ と $f(b)$ の値）をすべて比較して、全域的な最大値を特定する

Ex 9.9 Bernoulli 分布

$X_1, \ldots, X_n \overset{i.i.d.}{\sim} Bernoulli(p)$ とする

1. 尤度関数の構成：$L(p|\mathbf{x}) = \prod_{i=1}^{n} p^{x_i}(1-p)^{1-x_i} = p^y(1-p)^{n-y}, \quad y = \sum x_i$ 対数尤度関数をとることで計算が大幅に簡略化される：

$$\ell(p) = \log L(p|\mathbf{x}) = y \log p + (n-y)\log(1-p)$$

2. MLE の候補の導出 $(0 < y < n)$：$\frac{d}{dp}\ell(p) = 0 \Rightarrow \hat{p} = \frac{y}{n}$
3. 最大値の確認
   - 唯一性：$\hat{p} = \frac{y}{n}$ はこの方程式の唯一の解
   - 極大値：

$$\frac{d^2}{dp^2}\ell(p)\Big|_{p=\hat{p}} < 0 \Rightarrow \text{唯一の極大値}$$

   - 境界の確認：
     - $y = 0 : \ell(p) = n\log(1-p) \quad y = n : \ell(p) = n \log p$

     どちらの場合も関数は p に対して単調関数となる。$\hat{p} = y/n(= 0, 1)$ が最大値となることが確認される

Ex 9.10　二項分布（課題）

$X_1, \ldots, X_n \overset{i.i.d.}{\sim} Binomial(n, p)$ とする．p の MLE

Ex 9.11　正規分布

$X_1, \ldots, X_n \overset{i.i.d.}{\sim} N(\theta, 1)$ とする

1. 尤度関数の構成

$$L(\theta|\mathbf{x}) = \prod_{i=1}^{n} \frac{1}{(2\pi)^{1/2}} e^{-(1/2)(x_i-\theta)^2} = \frac{1}{(2\pi)^{n/2}} e^{-(1/2)\sum_{i=1}^{n}(x_i-\theta)^2}$$

2. MLE の候補の導出：$\frac{d}{d\theta} L(\theta|\mathbf{x}) = 0 \Rightarrow \sum_{i=1}^{n}(x_i - \theta) = 0 \Rightarrow \hat{\theta} = \frac{1}{n}\sum x_i = \bar{x}$
3. 最大値の確認
   - 唯一性：$\hat{\theta} = \bar{x}$ はこの方程式の唯一の解
   - 極大値：

$$\frac{d^2}{d\theta^2} L(\theta|\mathbf{x})\Big|_{\theta=\bar{x}} < 0 \Rightarrow \text{唯一の極大値}$$

   - 境界の確認：$\theta \to \pm\infty$ において $L(\theta)$ は 0 に収束する

Ex 9.12　正規分布

$X_1, \ldots, X_n \overset{i.i.d.}{\sim} N(\theta, \sigma^2)$ とする

1. 尤度関数の構成

$$L(\theta, \sigma^2 \mid \mathbf{x}) = \frac{1}{(2\pi\sigma^2)^{n/2}} e^{-(1/2)\sum_{i=1}^n (x_i-\theta)^2/\sigma^2}$$

計算を簡略化するため、対数をとる：

$$\ell(\theta, \sigma^2) = \log L(\theta, \sigma^2 \mid \mathbf{x}) = -\frac{n}{2}\log 2\pi - \frac{n}{2}\log\sigma^2 - \frac{1}{2}\sum_{i=1}^n (x_i-\theta)^2/\sigma^2$$

2. MLE の候補の導出：

$$\frac{\partial}{\partial\theta}\ell(\theta, \sigma^2) = \frac{1}{\sigma^2}\sum_{i=1}^n (x_i-\theta) = 0 \Rightarrow \hat{\theta} = \bar{x}$$

$$\frac{\partial}{\partial\sigma^2}\ell(\theta, \sigma^2) = -\frac{n}{2\sigma^2} + \frac{1}{2\sigma^4}\sum_{i=1}^n (x_i-\theta)^2 = 0 \Rightarrow \hat{\sigma}^2 = \frac{1}{n}\sum (x_i-\bar{x})^2$$

3. 最大値の確認
   - 唯一性：$\bar{x}, \frac{1}{n}\sum(x_i-\bar{x})^2$ は方程式の唯一の解

Supp 9.13　2 変数関数の極大値判定（一般論）

関数 $H(\theta_1, \theta_2)$ が点 $(\hat{\theta}_1, \hat{\theta}_2)$ で極大値を持つことを示すには、以下の 3 つの条件がすべて満たされている：

1. １次偏微分が 0 である（静止点）

$$\frac{\partial}{\partial \theta_1} H(\theta_1, \theta_2)\Big|_{\theta_1=\hat{\theta}_1, \theta_2=\hat{\theta}_2} = 0 \quad \text{および} \quad \frac{\partial}{\partial \theta_2} H(\theta_1, \theta_2)\Big|_{\theta_1=\hat{\theta}_1, \theta_2=\hat{\theta}_2} = 0$$

2. 2 次偏微分の少なくとも一方が負である

$$\frac{\partial^2}{\partial \theta_1^2} H(\theta_1, \theta_2)\Big|_{\theta_1=\hat{\theta}_1, \theta_2=\hat{\theta}_2} < 0 \quad \text{または} \quad \frac{\partial^2}{\partial \theta_2^2} H(\theta_1, \theta_2)\Big|_{\theta_1=\hat{\theta}_1, \theta_2=\hat{\theta}_2} < 0$$

3. 2 次偏微分のヤコビアンが正である

$$J = \begin{vmatrix} \frac{\partial^2}{\partial \theta_1^2} H & \frac{\partial^2}{\partial \theta_1 \partial \theta_2} H \\ \frac{\partial^2}{\partial \theta_1 \partial \theta_2} H & \frac{\partial^2}{\partial \theta_2^2} H \end{vmatrix}_{\theta_1=\hat{\theta}_1, \theta_2=\hat{\theta}_2} > 0$$

Ex 9.14　Eg 9.12 の続き

- 極大値の確認
  1. $\hat{\theta}, \hat{\sigma}^2$ を代入すると，１次偏微分が 0 である
  2. 2 次偏微分の少なくとも一方が負である

$$\frac{\partial^2}{\partial\theta^2}\ell(\theta,\sigma^2) = \frac{-n}{\sigma^2} < 0$$

  3. 2 次偏微分のヤコビアンが正である

$$\frac{\partial^2}{\partial(\sigma^2)^2}\ell(\theta,\sigma^2) = \frac{n}{2\sigma^4} - \frac{1}{\sigma^6}\sum(x_i-\theta)^2$$

$$\frac{\partial^2}{\partial\theta\partial\sigma^2}\log L = -\frac{1}{\sigma^4}\sum(x_i-\theta)$$

$$\begin{aligned} J(\bar{x},\hat{\sigma}^2) &= \frac{1}{\sigma^6}\left[\frac{-n^2}{2} + \frac{n}{\sigma^2}\sum(x_i-\theta)^2 - \frac{1}{\sigma^2}\left(\sum(x_i-\theta)\right)^2\right]\Big|_{\theta=\bar{x},\sigma^2=\hat{\sigma}^2} \\ &= \frac{1}{\hat{\sigma}^6}\frac{n^2}{2} > 0 \end{aligned}$$

- 境界の確認：$\theta \to \pm\infty, \sigma^2 \to \infty, \sigma^2 \to 0$，尤度は全体として 0 に収束します

ベイズ法

- 古典的統計（頻度論）: 母数 θ は「未知だが固定された値」とみなす
- ベイズ的統計: 母数 θ を変数とみなし、その変動を事前分布（prior distribution）$\pi(\theta|\xi)$ で表現する

$$\begin{cases} \mathbf{X}|\theta & \sim f(\mathbf{x}|\theta) \\ \theta & \sim \pi(\theta|\xi) \end{cases}$$

  - ξ は θ の事前分布の母数であり，超母数（hyperparameter）と呼ぶ
  - 観測データ $\mathbf{X} = \mathbf{x}$ を得た後、ベイズの定理を用いて事前分布を更新したものを事後分布（posterior distribution）$\pi(\theta|\mathbf{x}, \xi)$ と呼ぶ

$$\pi(\theta|\mathbf{x}, \xi) = \frac{f(\mathbf{x}|\theta)\pi(\theta|\xi)}{m(\mathbf{x}|\xi)}$$

  - $m(\mathbf{x}|\xi)$ は $\mathbf{X}$ の周辺分布

$$m(\mathbf{x}|\xi) = \int f(\mathbf{x}|\theta)\pi(\theta|\xi)\,d\theta$$

  - 事後分布の平均 $E[\theta|\mathbf{X}]$ をベイズ推定量（Bayes estimator）と呼ぶ

Ex 9.15　二項分布

$X_1, \ldots, X_n \overset{i.i.d.}{\sim} Bernoulli(p)$ とする．$\Rightarrow Y = \sum X_i \sim Binomial(n, p)$
事前分布：$p \sim Beta(\alpha, \beta)$ とする

- 同時分布 $f(y, p)$

$$f(y,p) = \left[\binom{n}{y} p^y (1-p)^{n-y}\right]\left[\frac{\Gamma(\alpha+\beta)}{\Gamma(\alpha)\Gamma(\beta)} p^{\alpha-1}(1-p)^{\beta-1}\right]$$
$$= \binom{n}{y}\frac{\Gamma(\alpha+\beta)}{\Gamma(\alpha)\Gamma(\beta)} p^{y+\alpha-1}(1-p)^{n-y+\beta-1}$$

- Y の周辺分布 (Beta-Binomial 分布)

$$f(y) = \int_0^1 f(y,p)\,dp = \binom{n}{y}\frac{\Gamma(\alpha+\beta)}{\Gamma(\alpha)\Gamma(\beta)}\frac{\Gamma(y+\alpha)\Gamma(n-y+\beta)}{\Gamma(n+\alpha+\beta)}$$ **(証)**

- p の事後分布

$$f(p|y) = \frac{f(y,p)}{f(y)} = \frac{\Gamma(n+\alpha+\beta)}{\Gamma(y+\alpha)\Gamma(n-y+\beta)} p^{y+\alpha-1}(1-p)^{n-y+\beta-1}$$
$$\Leftrightarrow p|y \sim Beta(y+\alpha, n-y+\beta)$$

$$\hat{p}_B = E[p] = \frac{y+\alpha}{\alpha+\beta+n}$$
$$\hat{p}_B = \left(\frac{n}{\alpha+\beta+n}\right)\left(\frac{y}{n}\right) + \left(\frac{\alpha+\beta}{\alpha+\beta+n}\right)\left(\frac{\alpha}{\alpha+\beta}\right)$$

Ex 9.16　正規分布　(証)

$X_1, \ldots, X_n \overset{i.i.d.}{\sim} N(\theta, \sigma^2)$ とし，事前分布：$\theta \sim N(\mu, \tau^2)$ とする．(σ^2, μ, τ^2 は既知)
事後分布の平均と分散

$$\hat{\theta}_B = E[\theta|\mathbf{x}] = \frac{n\tau^2}{n\tau^2 + \sigma^2}\bar{x} + \frac{\sigma^2}{n\tau^2 + \sigma^2}\mu$$

$$Var[\theta|\mathbf{x}] = \frac{\sigma^2\tau^2}{n\tau^2 + \sigma^2}$$

Def 9.17　共役事前分布 Conjugate prior distribution

事前分布 $\pi(\theta|\xi)$ とその事後分布 $\pi(\theta|\mathbf{x}, \xi)$ が同じ分布族に入るような事前分布を共役事前分布という

推定法の比較

- モーメント法
  - 簡単・粗い推定
  - 初期値や理論説明用に使われることが多い
  - 簡便だが、統計的最適性はあまり期待できない方法
- 最尤法
  - 大標本で特に強力
  - 頻度論的推定の標準的手法であり、理論的にも実用的にも最も広く使われる
- ベイズ法
  - 情報統合と不確実性評価に強い
  - 柔軟で解釈しやすいが、計算と事前分布の設定が鍵となる
  - 現代的計算環境と相性が良い

平均二乗誤差・バイアス

Def 9.18　平均二乗誤差 Mean Squared Error, MSE（精度の評価）

点推定量の平均二乗誤差：推定量と真の値 θ との差の二乗の期待値

$$E_\theta[(W-\theta)^2]$$

- $E_\theta[(W-\theta)^2] = Var_\theta[W] + (E_\theta[W]-\theta)^2 = Var_\theta[W] + (Bias_\theta[W])^2$
- 分散 ≈ 精度の欠如　バイアスの二乗 ≈ 正確性の欠如

Def 9.19　バイアス　偏り Bias（正確性の評価）

点推定量のバイアス：推定量の期待値と真の値 θ との差

$$Bias_\theta[W] = E_\theta[W] - \theta$$

- 推定量の精度を評価する
- 不偏推定量: バイアスが常に 0（$E_\theta[W]=\theta$）である推定量
- 不偏推定量の MSE：$E_\theta[(W-\theta)^2] = Var_\theta[W]$

Ex 9.20　正規分布

$X_1, \ldots, X_n \overset{i.i.d.}{\sim} N(\mu, \sigma^2)$ とする．
(μ, σ^2) の推定量（統計量）：$\bar{X} = \frac{1}{n}\sum X_i, S^2 = \frac{1}{n-1}\sum(X_i - \bar{X})^2$ は不偏推定量[4]

- $\bar{X}, S^2$ の MSE

$$E[(\bar{X} - \mu)^2] = Var[\bar{X}] = \frac{\sigma^2}{n}$$

$$E[(S^2 - \sigma^2)^2] = Var[S^2] = \frac{2\sigma^4}{n-1} \quad \text{（正規性の仮定が必要）}$$

σ^2 の MLE[5]：$\hat{\sigma}^2 = \frac{1}{n}\sum(x_i - \bar{x})^2$ バイアス

$$E[\hat{\sigma}^2] = \frac{n-1}{n}\sigma^2 \text{（偏った推定量）}$$

- $\hat{\sigma}^2$ の MSE

$$MSE(\hat{\sigma}^2) = E[(\hat{\sigma}^2 - \sigma^2)^2] = \frac{2n-2+1}{n^2}\sigma^4 = \frac{2n-1}{n^2}\sigma^4 < \frac{2\sigma^4}{n-1}$$

偏った推定量 $\hat{\sigma}^2$ が、不偏分散 S^2 よりも MSE が小さくなる（真の値に近い確率が高い）

[4] Thm 7.7
[5] Eg 9.12

最良不偏推定量

Def 9.21　**最良不偏推定量** best unbiased estimator、BUE・**一様最小分散不偏推定量** uniform minimum variance unbiased estimator, UMVUE

推定量 W^* が $\tau(\theta)$ の最良不偏推定量・一様最小分散不偏推定量であるとは、以下の 2 条件を満たす

1. W^* が不偏推定量 $E_\theta[W^*] = \tau(\theta)$
2. 他のいかなる不偏推定量 W と比較しても、その分散が最小である $Var_\theta[W^*] \leq Var_\theta[W]$

Ex 9.22　ポアソン分布

$X_1, \ldots, X_n \overset{i.i.d.}{\sim} Poisson(\lambda)$ とする．
λ の推定量（統計量）：$\bar{X} = \frac{1}{n}\sum X_i, S^2 = \frac{1}{n-1}\sum(X_i - \bar{X})^2$，

- 不偏性[6]：$E_\lambda[\bar{X}] = \lambda, E_\lambda[S^2] = \lambda$
- 推定量の分散：$\mathrm{Var}_\lambda[\bar{X}] = \lambda/n, Var_\lambda[S^2] = \frac{\lambda}{n}\left(1 + \frac{2n}{n-1}\lambda\right)$

$$Var_\lambda[\bar{X}] \leq Var_\lambda[S^2]$$

- $\forall a, a\bar{X} + (1-a)S^2$ は不変推定量，

$$\forall a, Var_\lambda[\bar{X}] \leq Var_\lambda[a\bar{X} + (1-a)S^2]??$$

この条件が満たされる場合、$\bar{X}$ は UMVUE となる。
満たされない場合、$\bar{X}$ は UMVUE ではない。

任意の不偏推定量の分散がそれ以下にはなり得ない下限値（下界）（$B(\theta)$，クラメール・ラオの下限 Cramér-Rao Lower Bound）を特定する

[6] Thm 7.7

Thm 9.23　クラメール・ラオの不等式 Cramér-Rao Inequality

$X_1, \ldots, X_n \sim f(\mathbf{x}|\theta)$ とき，$\forall$推定量 $W(\mathbf{X})$ s.t.

- 微分可能性: $\frac{d}{d\theta} E_\theta W(\mathbf{X}) = \int_{\mathcal{X}} \frac{\partial}{\partial\theta}[W(\mathbf{x})f(\mathbf{x}|\theta)]d\mathbf{x}$ が成立
- 分散の有限性: $Var_\theta[W(\mathbf{X})] < \infty$

$$Var_\theta[W(\mathbf{X})] \geq \frac{\left(\frac{d}{d\theta} E_\theta[W(\mathbf{X})]\right)^2}{E_\theta\left[\left(\frac{\partial}{\partial\theta}\log f(\mathbf{X}|\theta)\right)^2\right]}$$

(証)

- フィッシャー情報量（Fisher Information）：

$$I(\theta) = E_\theta\left[\left(\frac{\partial}{\partial\theta}\log f(\mathbf{X}|\theta)\right)^2\right] = E[S(\theta, \mathbf{X})^2]$$

- スコア関数（score function）：$S(\theta, \mathbf{X}) = \frac{\partial}{\partial\theta}\log f(\mathbf{X}|\theta)$
- $W(\mathbf{X})$ が不変推定量であるとき，
  $E_\theta[W(\mathbf{X})] = \tau(\theta) \Rightarrow \frac{d}{d\theta} E_\theta[W(\mathbf{X})] = \tau'(\theta)$

Thm 9.24　クラメール・ラオの不等式 Cramér-Rao Inequality (IID 標本)

$X_1, \ldots, X_n \overset{i.i.d.}{\sim} f(\mathbf{x}|\theta)$ とき，$\forall$推定量 $W(\mathbf{X})$ s.t.

- 微分可能性: $\frac{d}{d\theta} E_\theta W(\mathbf{X}) = \int_{\mathcal{X}} \frac{\partial}{\partial\theta}[W(\mathbf{x})f(\mathbf{x}|\theta)]d\mathbf{x}$ が成立
- 分散の有限性: $Var_\theta[W(\mathbf{X})] < \infty$

$$Var_\theta[W(\mathbf{X})] \geq \frac{\left(\frac{d}{d\theta} E_\theta[W(\mathbf{X})]\right)^2}{nE_\theta\left[\left(\frac{\partial}{\partial\theta}\log f(X|\theta)\right)^2\right]}$$

(証)

Supp 9.25 **(証)**

$f(x|\theta)$ が以下の条件を満たす場合

$$\frac{d}{d\theta} E_\theta \left(\frac{\partial}{\partial\theta} \log f(X|\theta) \right) = \int \frac{\partial}{\partial\theta} \left[\left(\frac{\partial}{\partial\theta} \log f(x|\theta) \right) f(x|\theta) \right] dx$$

$$\Rightarrow I(\theta) = E_\theta \left(\left(\frac{\partial}{\partial\theta} \log f(X|\theta) \right)^2 \right) = -E_\theta \left(\frac{\partial^2}{\partial\theta^2} \log f(X|\theta) \right)$$

Ex 9.26 **Eg 9.22 の続き**

$\tau(\lambda) = \lambda, \Rightarrow \tau'(\lambda) = 1$

$$E_\lambda \left(\left(\frac{\partial}{\partial\lambda} \log \prod_{i=1}^{n} f(X_i|\lambda) \right)^2 \right) = -nE_\lambda \left(\frac{\partial^2}{\partial\lambda^2} \log \frac{e^{-\lambda}\lambda^X}{X!} \right) = \frac{n}{\lambda} \quad \textbf{(証)}$$

$\forall$不偏推定量 W, $Var_\lambda W \geq \frac{1}{n/\lambda} = \frac{\lambda}{n}$

$\because Var_\lambda \bar{X} = \frac{\lambda}{n}, \therefore \bar{X}$ は UMVUE

Ex 9.27 **正規分布（課題）**

$X_1, \ldots, X_n \overset{i.i.d.}{\sim} N(\mu, \sigma^2)$ とする．σ^2 の不変推定量のクラメール・ラオの下限

一致性

Def 9.28　一致推定量 consistent estimator[7]（漸近的正確性）

推定量の列 $W_n = W_n(X_1, \ldots, W_n)$ が母数 θ の一致推定量の列であるとは，

$$\forall \epsilon > 0, \theta \in \Theta, \quad \lim_{n\to\infty} P_\theta(|W_n - \theta| < \epsilon) = 1 \Leftrightarrow \lim_{n\to\infty} P_\theta(|W_n - \theta| \geq \epsilon) = 0$$

Ex 9.29　正規分布

$X_1, \ldots \overset{i.i.d.}{\sim} N(\theta, 1)$ とする．$\bar{X}_n = \frac{1}{n}\sum_{i=1}^n X_i \sim N(\theta, \frac{1}{n})$

$$P_\theta(|\bar{X}_n - \theta| < \epsilon) \to 1 (n \to \infty) \quad \text{(証)}$$

[7] Def 8.2 確率収束

Thm 9.30

推定量の列 W_n が母数 θ の推定量である且つ以下の 2 つの条件を同時に満たすとき，$\forall\theta \in \Theta$, W_n は θ の一致推定量となる

- $\lim_{n\to\infty} Var_\theta W_n = 0$
- $\lim_{n\to\infty} Bias_\theta W_n = 0$

Thm 9.31

W_n が母数 θ の一致推定量であるとき，
$\forall a_1, a_2, \ldots, b_1, b_2, \ldots$ （実数の列）s.t.,

- $\lim_{n\to\infty} a_n = 1$
- $\lim_{n\to\infty} b_n = 0$

$\Rightarrow U_n = a_n W_n + b_n$ も θ の一致推定量となる

Thm 9.32　MLE の一致性

$X_1, X_2, \ldots \overset{i.i.d.}{\sim} f(x|\theta), L(\theta|x) = \prod_{i=1}^{n} f(x_1|\theta)$ が尤度関数，$\hat{\theta}$ が θ の MLE，$\tau(\theta)$ が θ の連続関数であるとする．$f(x|\theta), L(\theta|x)$ が正則条件 (regularity conditions)[8]を満たす下で

$$\forall \epsilon > 0, \theta \in \Theta, \quad \lim_{n \to \infty} P_\theta(|\tau(\hat{\theta}) - \tau(\theta)| \geq \epsilon) = 0$$

$\tau(\hat{\theta})$ は $\tau(\theta)$ の一致推定量となる

- MLE：$\tau(\hat{\theta}) \xrightarrow{P} \tau(\theta) \Rightarrow \tau(\hat{\theta})$ は $\tau(\theta)$ の一致推定量となる

[8]正則性 regularity conditions とは、一般的に応用の範囲が広く、理論的な展開を容易にする条件を指す

Supp 9.33　正則条件の各項目

1. IID：$X_i \overset{i.i.d.}{\sim} f(x|\theta)$
2. パラメータの識別可能性 (Identifiability)：$\theta \neq \theta' \Rightarrow f(x|\theta) \neq f(x|\theta')$
3. $f(x|\theta)$ は、すべての θ に対して同じサポートを持つ且つ微分可能
4. 真の値 θ は Θ の内点です
5. f は θ に対して２次微分可能
6. $\int f(x|\theta)\,dx$ は θ に対して２次微分可能であり，微分は積分との交換が可能
7. f は θ に対して３次微分可能であり，定数 $c > 0$ と関数 $M(x)$ が存在する（即ち，対数尤度関数の３次微分が、真の値 θ_0 の近傍で発散しないこと）

$$|\frac{\partial^3}{\partial\theta^3}\log f(x;\theta)| \leq M(x), \quad \forall\theta \in (\theta_0 - c, \theta_0 + c), E_{\theta_0}[M(X)] < \infty$$

有効性

Def 9.34　漸近分散 asymptotic variance（漸近的精度）

推定量 T_n に対して、$k_n(T_n - \tau(\theta)) \xrightarrow{D} N(0, \sigma^2)$（分布収束）が成り立つとする。$\sigma^2$ を漸近分散・T_n の極限分布の分散と呼ぶ

Supp 9.35　極限分散 Limiting variance

推定量 T_n と定数列 $\{k_n\}$ に対して、以下の極限が存在し有限であるとき

$$\lim_{n\to\infty} k_n Var[T_n] = \tau^2 < \infty$$

τ^2 を、極限分散・分散の極限と呼びます。

例：$X_1, X_2, \ldots \overset{i.i.d.}{\sim} (\mu, \sigma^2)$, $T_n = \bar{X}_n$ とする，$\lim \sqrt{n} Var[\bar{X}_n] = \sigma^2/n$ は T_n の極限分散となる

$\frac{1}{\mu}$ を推定するために $T_n = \frac{1}{\bar{X}_n}$ を用いると問題が生じる

- 厳密な計算: $Var[T_n] = \infty$ となり、極限分散も無限大に発散する
- 近似的な計算（デルタ法）：$Var[T_n] \approx \frac{\sigma^2}{n\mu^4} < \infty$

Def 9.36　漸近有効 asymptotic efficient

推定量の列 W_n が以下の条件を満たすとき，

$$\sqrt{n}[W_n - \tau(\theta)] \xrightarrow{D} N(0, v(\theta)), \quad v(\theta) = \frac{[\tau'(\theta)]^2}{I(\theta)} = \frac{[\tau'(\theta)]^2}{E_\theta\left[\left(\frac{\partial}{\partial\theta}\log f(\mathbf{X}|\theta)\right)^2\right]}$$

W_n は $\tau(\theta)$ に対して漸近有効であるという

- $\tau(\theta) = \theta, \sqrt{n}[W_n - \theta] \xrightarrow{D} N(0, 1/I(\theta))$[9]
- W_n の漸近分散 $v(\theta)$ はクラメール・ラオの下限に達する

[9] Thm 9.23-3

Thm 9.37　MLE の漸近有効性

$X_1, X_2, \ldots \overset{i.i.d.}{\sim} f(x|\theta), L(\theta|x) = \prod_{i=1}^{n} f(x_1|\theta)$ が尤度関数，$\hat{\theta}$ が θ の MLE，$\tau(\theta)$ が θ の連続関数であるとする．$f(x|\theta), L(\theta|x)$ が正則条件を満たす下で

$$\sqrt{n}[\tau(\hat{\theta}) - \tau(\theta)] \xrightarrow{D} N(0, v(\theta)), \quad v(\theta) = \text{クラメール・ラオの下限}$$ **(証)**

- MLE：$\tau(\hat{\theta})$ は $\tau(\theta)$ の一致且つ漸近有効性推定量となる

Ex 9.38　漸近正規性

$\sqrt{n}\frac{W_n - \mu}{\sigma} \xrightarrow{D} Z, Z \sim N(0,1)$ スラツキーの定理[10]より

$$W_n - \mu = (\frac{\sigma}{\sqrt{n}})(\sqrt{n}\frac{W_n - \mu}{\sigma}) \xrightarrow{D} \lim_{n\to\infty}(\frac{\sigma}{\sqrt{n}})Z = 0$$

$\Rightarrow W_n - \mu \xrightarrow{D/P} 0$[11]

- 漸近正規性 $\Rightarrow$ 一致性

[10] Thm 8.13
[11] Def 8.10 点 4

レポート

課題 9.39

BEEF+ Report10-11